Principales factores del estrés en desarrolladores

Análisis e interpretación de datos | Actividad 2

Fecha límite de entrega: 25 de mayo 2026

Equipo: 1054E

Estudiante	Afiliación	Rol
Luis Javier Ceballos Sepúlveda	UNIR	Desarrollador de código
José Luis Sánchez Noguez	UNIR	Revisor de código
César Goavanni Gómez Camargo	UNIR	Infraestructura de contenedores y propuesta de análisis

1. Introducción y estado del tema: El estrés requiere prevención.

El estrés en los desarrolladores en la actualidad es un problema que consideramos debe ser atendido por cada empleador para evitar el fenómeno llamado burnout que causa afectaciones en diversos niveles, desde físicos como la fatiga y cansancio, hasta de salud mental como aislamiento, depresión y ansiedad. Es por ello que este análisis con fundamento estadístico pretende identificar los principales factores que generan estrés en los desarrolladores para los cuales los empleadores pueden aplicar medidas de prevención mediante ajustes en su cultura laboral.

1.1. Resumen

Este trabajo analiza la relación entre la experiencia laboral (medida en años), las horas diarias de trabajo, las horas de sueño y los niveles de estrés en los desarrolladores. Mediante un análisis estadístico comparativo, se evaluaron dos enfoques: un modelo de regresión lineal estándar (Modelo 1) considerando solo las horas diarias de trabajo y un modelo de regresión lineal agregando las variables de experiencia laboral y horas de sueño (Modelo 2) para identificar la relación entre ellas. Los resultados evidencian que son las horas diarias de trabajo las que más impacto tienen en el estrés de los desarrolladores independiente de las horas de sueño o del nivel de experiencia que tengan desarrollando código. Esto sugiere que el alivio del estrés disminuye de forma proporcional, alineándose de manera más realista con la psicología humana e implementando estrategias corporativas en su cultura laboral para que la cantidad de horas dedicadas a reuniones tenga un límite para conseguir un balance entre la planeación, la ejecución y las horas de sueño. Las conclusiones extraídas ofrecen un marco empírico para que los equipos analíticos implementen estrategias focalizadas en recursos humanos, detectando tempranamente el desgaste en los profesionales tecnológicos.

2. Metodología

Considerando que el data set de kaggle conformado por datos de desarrolladores de software que contiene la variable numérica de las horas diarias de trabajo, las horas en reuniones, el nivel de estrés y las horas de sueño, procedimos a establecer el modelo de regresión lineal que permitiera identificar la relación entre las horas diarias de trabajo y el nivel de estrés.

El primer paso para conseguir este objetivo al ser un trabajo en equipo, fue homologar las versiones de las herramientas que utilizaremos como Python y MongoDB, por lo cual utilizamos Docker para utilizar la versión más actual de MongoDB, la versión Python 3.9 que consideramos más estable para las librerías que vamos a utilizar como pandas para el trabajo de DataFrames, pymongo para la persistencia de datos, statsmodels para los modelos de regresión lineal, matplotlib y seaborn para graficar los modelos e interpretación visual de resultados.

Así mismo se creó un volumen nombrado en Docker para la lectura de la base de datos.

Posteriormente la interacción con los demás integrantes del equipo se facilitó utilizando un repositorio en GitHub para contar con la versión más reciente del código y el avance en el análisis.

Una vez que obtuvimos el espacio de trabajo homologado y configurado, iniciamos con la exploración de la base de datos, encontrando que las variables de interés son numéricas lo cual nos permitió cumplir con el supuesto para aplicar regresión lineal, así mismo observamos que si bien existe una variable categórica que indica el nivel de burnout, consideramos que no era necesaria incluirla en este análisis por medio de métodos de coerción como One-Hot Encoding para llevarla al tipo de dato numérico ya que la variable nivel de estrés es numérica y guarda una alta correlación con esta variable, por lo cual optamos por omitirla en éste análisis.

Como parte de la limpieza de datos, eliminamos aquellos registros del data set que tienen un valor nulo en la variable dependiente que es el nivel de estrés ya que de asignar la media o mediana implicaría un cocinado de datos que generaría sesgos en el objetivo de este trabajo; así mismo decidimos completar con la mediana aquellos registros que tienen un valor nulo en las variables independientes de interés, que en este caso son horas diarias de trabajo, horas en reuniones, horas de sueño y años de experiencia, aunque también podíamos haberlos completado con la media puesto que la distribución de la población es estándar, decidimos la mediana para volver los modelos menos sensibles a valores atípicos.

Al decidir utilizar el modelo de regresión lineal, exploramos también el gráfico Q-Q (quiantile – quantile) para validar la normalidad, es decir, que los residuos o errores del modelo siguen una distribución normal, lo cual se confirmó visualmente ya que los puntos de los residuos en el gráfico se alinean a la línea recta que se dibuja.

Cabe mencionar que la propuesta de las variables independientes para éste análisis obedece a que, luego de observar su interacción en el data set mediante un mapa de calor, identificamos que tienen poca relación entre ellas con lo cual evitamos la colinealidad o multicolinealidad, la cual sí fue identificada entre las variables tiempo en pantalla y horas diarias de trabajo siendo de 0.92 el nivel de correlación, así que procedimos a omitir la primera puesto que consideramos que las horas diarias de trabajo tienen contempladas incluso las horas en reuniones presenciales, por lo tanto aporta más valor al modelo.

Buscando un reforzamiento para evitar colinealidad o multicolinealidad, procedimos a generar la matriz de correlación de Pearson que nos confirmó que las variables que estamos considerando como independientes, realmente aportan valor al modelo de regresión lineal, encontrando que el estrés tiene un nivel de correlación de 0.59 con las horas diarias de trabajo, 0.34 con las horas en reunión y de -0.01 con los años de experiencia.

Una vez que contamos con el análisis exploratorio de datos, procedimos al modelado de la línea de regresión simple, considerando la variable horas diarias de trabajo como el principal factor del burnout en desarrolladores. Posteriormente procedimos con el modelado de la línea de regresión múltiple agregando las variables horas en reunión, años de experiencia y horas de sueño, para llegar a una sola conclusión considerando el resultado de ambos modelos.

2.1. Modelo 1 regresión lineal simple: Horas diarias de trabajo como principal causa de estrés.

Basados en el supuesto de que las horas diarias de trabajo son la causa principal de estrés, aplicamos un modelo de regresión simple identificando el coeficiente de determinación R^2 es muy bajo, siendo éste de 0.3536, lo que nos indica que el modelo no representa satisfactoriamente la realidad del data set, sin embargo observamos también que el coeficiente β o peso indica que por cada hora adicional de trabajo, el nivel de estrés aumenta en 4.9131 puntos en su escala absoluta.

2.2. Modelo 2 regresión lineal múltiple: Horas diarias de trabajo como principal causa de estrés.

Una vez que agregamos más variables (horas de sueño, experiencia laboral y horas en reunión) utilizando un modelo de regresión múltiple, identificamos que el coeficiente de determinación R^2 mejora significativamente, siendo éste de 0.4744, que con base en los efectos que representa en el contexto de la psicología humana[1] nos indica que el modelo representa satisfactoriamente la realidad del data set; así mismo observamos el coeficiente β o peso sigue indicando que por cada hora adicional de trabajo, el nivel de estrés aumenta en 4.9131 puntos en su escala absoluta y que también por cada hora adicional en reuniones, el nivel de estrés aumenta en 2.8627 puntos.

Por otro lado, también encontramos que el coeficiente β o peso tiene una relación inversamente proporcional entre las variables de estrés y los años de experiencia o entre el estrés y las horas de sueño, siendo éste de -0.041 y -3.904 correspondientemente.

3. Resultados obtenidos

La conclusión de lo encontrado en el modelo de regresión lineal simple, considerando solo la variable independiente de las horas diarias de trabajo y el modelo de regresión lineal múltiple, es que confirmamos es el factor que más tiene influencia en el estrés en los desarrolladores, así mismo identificamos que las horas en reuniones también tienen un impacto significativo en el nivel de estrés y que si bien los años de experiencia como las horas de sueño atenúan el nivel de estrés, es el sueño el que mayor impacto tiene en la reducción del burnout en desarrolladores.

La diferencia entre los dos modelos es que el de regresión múltiple mejora su aproximación a la realidad del data set y confirma que las horas de trabajo son el principal factor de estrés en los desarrolladores.

1. Conclusiones y líneas futuras

Tanto las horas diarias de trabajo como las horas en reuniones tienen un impacto significativo en el nivel de estrés de los desarrolladores, lo cual está fuertemente ligado al fenómeno actual llamado burnout con implicaciones graves en salud y calidad de vida de las personas que se dedican profesionalmente a este campo.

Derivado de lo anterior, recomendamos ampliamente a los empleadores a fortalecer su cultura laboral estableciendo límite en la cantidad de horas que se dedican a las reuniones para apoyar en la disminución del nivel de estrés entre sus colaboradores, ya que independientemente de si se trata de roles senior o junior con mucha o poca experiencia, este factor es determinante para evitar el burnout, permitiendo el cuidado de la salud física, emocional y mental de las personas.

Referencias

1. *IONOS. (2024, 16 de julio). R cuadrado en R: interpretación y cálculo.* https://www.ionos.es/digitalguide/paginas-web/desarrollo-web/r-cuadrado-en-r/